

优化方法

2016-2017学年工科硕士课程

第1章 引论

1.0 数学基础知识

- n 维向量, $a = (a_1, a_2, \dots, a_n)^T$,

1.0 数学基础知识

- n 维向量, $a = (a_1, a_2, \dots, a_n)^T$,
- 内积, $a \cdot b = a^T b$,

1.0 数学基础知识

- n 维向量, $a = (a_1, a_2, \dots, a_n)^T$,
- 内积, $a \cdot b = a^T b$,
- 内点, 边界点, 闭集, 开集,

1.0 数学基础知识

- n 维向量, $a = (a_1, a_2, \dots, a_n)^T$,
- 内积, $a \cdot b = a^T b$,
- 内点, 边界点, 闭集, 开集,
- 多元函数 $f: \mathbf{R}^n \rightarrow \mathbf{R}$, f 的梯度

$$\operatorname{grad} f(x) = \nabla f(x) = \left(\frac{\partial f}{\partial x_1}, \dots, \frac{\partial f}{\partial x_n} \right)^T,$$

1.0 数学基础知识

- n 维向量, $a = (a_1, a_2, \dots, a_n)^T$,
- 内积, $a \cdot b = a^T b$,
- 内点, 边界点, 闭集, 开集,
- 多元函数 $f: \mathbf{R}^n \rightarrow \mathbf{R}$, f 的梯度

$$\text{grad} f(x) = \nabla f(x) = \left(\frac{\partial f}{\partial x_1}, \dots, \frac{\partial f}{\partial x_n} \right)^T,$$

- f 的 **海森阵** (Hesse阵)

$$\nabla^2 f(x) = \left(\frac{\partial^2 f(x)}{\partial x_i \partial x_j} \right)_{n \times n}.$$

方向导数和泰勒公式

- f 在 x 处关于方向 d 的方向导数,

$$f'(x, d) = \lim_{t \downarrow 0} \frac{f(x + td) - f(x)}{t} = \nabla f(x)^T d.$$

方向导数和泰勒公式

- f 在 x 处关于方向 d 的方向导数,

$$f'(x, d) = \lim_{t \downarrow 0} \frac{f(x + td) - f(x)}{t} = \nabla f(x)^T d.$$

方向导数和泰勒公式

- f 在 x 处关于方向 d 的方向导数,

$$f'(x, d) = \lim_{t \downarrow 0} \frac{f(x + td) - f(x)}{t} = \nabla f(x)^T d.$$

几何意义?

方向导数和泰勒公式

- f 在 x 处关于方向 d 的方向导数,

$$f'(x, d) = \lim_{t \downarrow 0} \frac{f(x + td) - f(x)}{t} = \nabla f(x)^T d.$$

几何意义?

- 多元函数的泰勒展开公式,

方向导数和泰勒公式

- f 在 x 处关于方向 d 的方向导数,

$$f'(x, d) = \lim_{t \downarrow 0} \frac{f(x + td) - f(x)}{t} = \nabla f(x)^T d.$$

几何意义?

- 多元函数的泰勒展开公式,

方向导数和泰勒公式

- f 在 x 处关于方向 d 的方向导数,

$$f'(x, d) = \lim_{t \downarrow 0} \frac{f(x + td) - f(x)}{t} = \nabla f(x)^T d.$$

几何意义?

- 多元函数的泰勒展开公式,

$$f(x) = f(x_0) + \nabla f(x_0)^T (x - x_0) + \frac{1}{2} (x - x_0)^T \nabla^2 f(x) (x - x_0) + o(\|x - x_0\|^2).$$

方向导数和泰勒公式

- f 在 x 处关于方向 d 的方向导数,

$$f'(x, d) = \lim_{t \downarrow 0} \frac{f(x + td) - f(x)}{t} = \nabla f(x)^T d.$$

几何意义?

- 多元函数的泰勒展开公式,

$$f(x) = f(x_0) + \nabla f(x_0)^T (x - x_0) + \frac{1}{2} (x - x_0)^T \nabla^2 f(x) (x - x_0) + o(\|x - x_0\|^2).$$

- 点 x_0 的 ε 邻域

$$N(x_0, \varepsilon) = \{x \mid \|x - x_0\| < \varepsilon\}.$$

其中向量模 $\|x\| = [\sum_{i=1}^n x_i^2]^{1/2}$, 称为欧氏范数. $\|x - x_0\|$ 表示两点之间的距离, 称为欧氏距离.

1.1 最优化问题举例

利用最优化的理论和方法解决生产实际和自然科学中的具体问题,一般分为两个步骤:

- (1) 建立数学模型.
- (2) 进行数学加工和求解.

例1.1

某化工厂生产A,B,C,D四种产品,生产每种产品一吨所消耗的工时和产值如下表:

产品	A	B	C	D
工时(小时)	100	300	400	75
产值(千元)	1	5	10	0.5

要求全厂产值在1000万元以上,求当消耗的总工时最少时,该厂生产各种产品的数量.

例1.1

某化工厂生产A,B,C,D四种产品,生产每种产品一吨所消耗的工时和产值如下表:

产品	A	B	C	D
工时(小时)	100	300	400	75
产值(千元)	1	5	10	0.5

要求全厂产值在1000万元以上,求当消耗的总工时最少时,该厂生产各种产品的数量.

$$\begin{aligned} \min \quad & y = 100x_1 + 300x_2 + 400x_3 + 75x_4 \\ \text{s.t.} \quad & x_1 + 5x_2 + 10x_3 + 0.5x_4 \geq 10000, \\ & x_i \geq 0, \quad i = 1, 2, 3, 4. \end{aligned} \tag{1-1}$$

例1.7

设有 B 亿元资金可用于投资,有 m 个项目 A_1, A_2, \dots, A_m 可供挑选. 若对项目 A_i 进行投资,需花费资金 a_i 亿元,可获益 c_i 亿元,试确定最佳的投资方案.

例1.7

设有B亿元资金可用于投资,有 m 个项目 A_1, A_2, \dots, A_m 可供挑选. 若对项目 A_i 进行投资,需花费资金 a_i 亿元,可获益 c_i 亿元,试确定最佳的投资方案.

$$\begin{aligned} \min \quad & f_1(x) = \sum_{i=1}^m a_i x_i \\ \max \quad & f_2(x) = \sum_{i=1}^m c_i x_i \\ \text{s.t.} \quad & \sum_{i=1}^m a_i x_i \leq B, \\ & x_i \in I = \{0, 1\}, \quad i = 1, \dots, m. \end{aligned} \tag{1-7}$$

1.2 最优化的基本概念

1.2.1 最优化问题的提法和基本概念

最优化问题可简写为

$$\begin{array}{ll}\min & f(x) \\ \text{s.t.} & g_i(x) \leq 0, \quad i = 1, 2, \dots, m, \\ & h_j(x) = 0, \quad j = m+1, m+2, \dots, p.\end{array} \quad (2-1)$$

令

$$R = \{x | g_i(x) \leq 0, i = 1, 2, \dots, m; h_j(x) = 0, j = m+1, m+2, \dots, p\},$$

称 R 为问题(2-1)的可行集或容许集,称 $x \in R$ 为可行解或容许解.

最优解的定义

定义2.1

- 若有 $x^* \in R$, 使得 $\forall x \in R$, 均有 $f(x^*) \leq f(x)$, 则称 x^* 为问题(2-1)的(全局)最优解(点)或全局极小点.

定义2.1

- 若有 $x^* \in R$, 使得 $\forall x \in R$, 均有 $f(x^*) \leq f(x)$, 则称 x^* 为问题(2-1)的(全局)最优解(点)或全局极小点.
- 若有 $x^* \in R$, 使得 $\forall x \in R \cap N(x^*, \varepsilon)$, 均有 $f(x^*) \leq f(x)$, 则称 x^* 为问题(2-1)的局部最优解(点)或局部极小点.

最优解的定义

定义2.1

- 若有 $x^* \in R$, 使得 $\forall x \in R$, 均有 $f(x^*) \leq f(x)$, 则称 x^* 为问题(2-1)的(全局)最优解(点)或全局极小点.
- 若有 $x^* \in R$, 使得 $\forall x \in R \cap N(x^*, \varepsilon)$, 均有 $f(x^*) \leq f(x)$, 则称 x^* 为问题(2-1)的局部最优解(点)或局部极小点.
- 严格全局极小点, $\forall x \in R, x \neq x^*, <$

最优解的定义

定义2.1

- 若有 $x^* \in R$, 使得 $\forall x \in R$, 均有 $f(x^*) \leq f(x)$, 则称 x^* 为问题(2-1)的(全局)最优解(点)或全局极小点.
- 若有 $x^* \in R$, 使得 $\forall x \in R \cap N(x^*, \varepsilon)$, 均有 $f(x^*) \leq f(x)$, 则称 x^* 为问题(2-1)的局部最优解(点)或局部极小点.
- 严格全局极小点, $\forall x \in R, x \neq x^*, <$
- 严格局部极小点, $\forall x \in R \cap N(x^*, \varepsilon), x \neq x^*, <$

定理2.1

设 $f(x), g_i(x), i = 1, 2, \dots, m, h_j(x), j = m + 1, \dots, p$ 在 \mathbf{R}^n 上连续, 则问题(2-1)的可行集 R 为闭集, 它的全局最优集合也为闭集.

定理2.1

设 $f(x), g_i(x), i = 1, 2, \dots, m, h_j(x), j = m + 1, \dots, p$ 在 \mathbf{R}^n 上连续, 则问题(2-1)的可行集 R 为闭集, 它的全局最优集合也为闭集.

定理2.2(一阶必要条件)

设 $f(x) \in C^1$ 定义在 $\Omega \subset \mathbf{R}^n$ 上, x^* 是 Ω 的一个内点, 若 x^* 为 $f(x)$ 的一个极小点, 则 $\nabla f(x^*) = 0$.

满足条件 $\nabla f(x^*) = 0$ 的点 x^* 称为 $f(x)$ 的稳定点或驻点.

1.2.2 二维最优化问题的几何意义

研究如下的问题:

$$\begin{aligned} \min \quad & z = f(x_1, x_2) = (x_1 - 1.5)^2 + x_2^2 \\ \text{s.t.} \quad & g_1(x) = x_1^2 + x_2^2 - 1 \leq 0 \\ & g_2(x) = 2x_1 + x_2 - 1 \geq 0 \\ & g_3(x) = x_1 \geq 0 \\ & g_4(x) = x_2 \geq 0 \end{aligned} \tag{2-3}$$

1.2.2 二维最优化问题的几何意义

研究如下问题:

$$\begin{aligned} \min \quad & z = f(x_1, x_2) = (x_1 - 1.5)^2 + x_2^2 \\ \text{s.t.} \quad & g_1(x) = x_1^2 + x_2^2 - 1 \leq 0 \\ & g_2(x) = 2x_1 + x_2 - 1 \geq 0 \\ & g_3(x) = x_1 \geq 0 \\ & g_4(x) = x_2 \geq 0 \end{aligned} \quad (2-3)$$

图解法, 其求解步骤可概述如下:

- (1) 画出问题的可行集 R 的图形.
- (2) 作出目标函数的等值线族.
- (3) 通过观察等值线族与 R , 确定使目标函数取得最小值的可行点 x^* , 即为所求的最优解.

1.2.2 最优化问题分类 I

- (1) **线性规划** (Linear Programming, LP) 若 $f(x)$, $g_i(x)$, $h_j(x)$ 都是 x 的线性函数.
- (2) **二次规划** (Quadratic Programming, QP) 若 $f(x)$ 是 x 的二次函数, $g_i(x)$, $h_j(x)$ 都是的线性函数.
- (3) **非线性规划** (Nonlinear Programming, NLP) 若 $f(x)$, $g_i(x)$, $h_j(x)$ 中至少有一个是 x 的非线性函数. 一般分为两种:无约束非线性规划问题和约束非线性规划问题.
- (4) **整数规划** (Integer Programming, IP) 若某些或全部设计变量取非负的整数值.
 - 纯整数规划问题或全整数规划问题.
 - 混合型整数规划问题.
 - 0-1规划问题.
- (5) **几何规划** (Geometric Programming) 若目标函数和约束函数都是设计变量的广义多项式, 形如 $\phi(x) = \sum_{i=1}^m c_i \prod_{j=1}^n x_j^{r_{ij}}$, 其中 c_i , r_{ij} 可取任意实数值, $x_j > 0$.

1.2.2 最优化问题分类 II

- (6) 多目标规划 (Multiobjective Programming) 若目标函数 $f(x) = (f_1(x), f_2(x), \dots, f_p(x))^T, p \geq 2$.
- (7) 其他 动态规划, 不可微规划, 参数规划, 随机规划等.

1.3 凸集和凸函数

凸集和凸函数的理论一般称为凸分析,是最优化的理论基础,本节介绍凸集和凸函数最基本的知识.

1.3.1 凸集

定义3.1

设 $\Omega \subset \mathbf{R}^n$,如果对于任意的点 $x, y \in \Omega$,连接点 x, y 的线段上的一切点都在 Ω 中,即对 $0 \leq \mu \leq 1$ 的一切 μ ,总有 $\mu x + (1 - \mu)y \in \Omega$,则称 Ω 为一个凸集.

显然单点集和整个空间 \mathbf{R}^n 都是凸集,我们规定空集 \emptyset 为凸集.

凸集的例子

例3.1

满足线性规划问题的约束条件 $Ax = b, x \geq 0$ 的一切点 x 所组成的集合 R 是一个凸集.

凸集的例子

例3.1

满足线性规划问题的约束条件 $Ax = b, x \geq 0$ 的一切点 x 所组成的集合 R 是一个凸集.

例3.2

设 $c \neq 0$ 是已给定的 n 维向量, b 是已给常数, 集合

$$H = \{x | x \in \mathbf{R}^n, c^T x = b\}$$

称为超平面, 它也是一个凸集.

定义3.2

设实数

$$\alpha_i \geq 0 (i = 1, 2, \dots, p), \sum_{i=1}^p \alpha_i = 1, x^i \in \mathbf{R}^n (i = 1, 2, \dots, p),$$

称 $x = \sum_{i=1}^p \alpha_i x^i$ 为点 x^1, x^2, \dots, x^p 的一个凸组合.

定义3.2

设实数

$$\alpha_i \geq 0 (i = 1, 2, \dots, p), \sum_{i=1}^p \alpha_i = 1, x^i \in \mathbf{R}^n (i = 1, 2, \dots, p),$$

称 $x = \sum_{i=1}^p \alpha_i x^i$ 为点 x^1, x^2, \dots, x^p 的一个凸组合.

定理3.1

集合 $\Omega \subset \mathbf{R}^n$ 为凸集的充要条件是: 点 $x^i \in \Omega, i = 1, 2, \dots, p$ 的任意凸组合仍在 Ω 中.

证明.

充分性显然. 必要性用数学归纳法证明.



定理3.2

任意一组凸集的交集仍为凸集.

定理3.2

任意一组凸集的交集仍为凸集.

定义3.3

包含集合 $\Omega \subset \mathbf{R}^n$ 的所有凸集的交集称为 Ω 的凸包, 记为 $\text{Co}(\Omega)$ 或 $H(\Omega)$.

有定理3.2可知 $\text{Co}(\Omega)$ 为凸集, 它实际上是 \mathbf{R}^n 中包含 Ω 的最小凸集.

定理3.2

任意一组凸集的交集仍为凸集.

定义3.3

包含集合 $\Omega \subset \mathbf{R}^n$ 的所有凸集的交集称为 Ω 的凸包, 记为 $\text{Co}(\Omega)$ 或 $H(\Omega)$.

有定理3.2可知 $\text{Co}(\Omega)$ 为凸集, 它实际上是 \mathbf{R}^n 中包含 Ω 的最小凸集.

定义3.4

设 $\Omega \subset \mathbf{R}^n$, 如果对于任何 $x \in \Omega$ 及所有的 $\alpha \geq 0$, 都有 $\alpha x \in \Omega$, 则称集合 Ω 为一个锥. 一个同时为凸集的锥称为凸锥.

1.3.2 凸函数

定义3.5

设 $f(x)$ 是定义在非空凸集 $\Omega \subset \mathbf{R}^n$ 上的函数,若对任意 $x, y \in \Omega$,不等式

$$f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y) \quad (3-1)$$

对于 $0 \leq \lambda \leq 1$ 中的一切 λ 都成立,则称 $f(x)$ 为 Ω 上的凸函数.

1.3.2 凸函数

定义3.5

设 $f(x)$ 是定义在非空凸集 $\Omega \subset \mathbf{R}^n$ 上的函数,若对任意 $x, y \in \Omega$,不等式

$$f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y) \quad (3-1)$$

对于 $0 \leq \lambda \leq 1$ 中的一切 λ 都成立,则称 $f(x)$ 为 Ω 上的凸函数.

- 严格凸函数, $x \neq y, \lambda \in (0, 1), <$
- 凹函数, \geq
- 严格凹函数, $x \neq y, \lambda \in (0, 1), >$

凸函数的性质

定理3.3

设 $f_1(x)$, $f_2(x)$ 是凸集 $\Omega \subset \mathbf{R}^n$ 上的凸函数, 则 $f_1(x) + f_2(x)$ 在 Ω 上也是凸的.

凸函数的性质

定理3.3

设 $f_1(x)$, $f_2(x)$ 是凸集 $\Omega \subset \mathbf{R}^n$ 上的凸函数, 则 $f_1(x) + f_2(x)$ 在 Ω 上也是凸的.

定理3.4

设 $f(x)$ 是凸集 $\Omega \subset \mathbf{R}^n$ 上的凸函数, 则对任意常数 $a \geq 0$, 函数 $af(x)$ 也是凸的.

凸函数的性质

定理3.3

设 $f_1(x), f_2(x)$ 是凸集 $\Omega \subset \mathbf{R}^n$ 上的凸函数, 则 $f_1(x) + f_2(x)$ 在 Ω 上也是凸的.

定理3.4

设 $f(x)$ 是凸集 $\Omega \subset \mathbf{R}^n$ 上的凸函数, 则对任意常数 $a \geq 0$, 函数 $af(x)$ 也是凸的.

推论

设 $f_1(x), f_2(x), \dots, f_p(x)$ 是凸集 $\Omega \subset \mathbf{R}^n$ 上的凸函数,
 $\lambda_i \geq 0 (i = 1, 2, \dots, p)$, 则非负的线性组合 $\sum_{i=1}^p \lambda_i f_i(x)$ 在 Ω 上也是凸的.

定理3.5

设 $f(x)$ 是凸集 $\Omega \subset \mathbf{R}^n$ 上的凸函数,则对任一个实数 c ,水平集

$$\Omega_c = \{x | x \in \Omega, f(x) \leq c\}$$

是凸集.

定理3.5

设 $f(x)$ 是凸集 $\Omega \subset \mathbf{R}^n$ 上的凸函数,则对任一个实数 c ,水平集

$$\Omega_c = \{x | x \in \Omega, f(x) \leq c\}$$

是凸集.

推论

设 $f_1(x), f_2(x), \dots, f_p(x)$ 是凸集 $\Omega \subset \mathbf{R}^n$ 上的凸函数, $c_i (i = 1, 2, \dots, p)$ 为实常数,则 Ω 中同时满足 $f_1(x) \leq c_1, \dots, f_p(x) \leq c_p$ 的点构成的集合 Ω_c 为凸集.

凸函数的充要条件I

定理3.6

定义在凸集 $\Omega \subset \mathbf{R}^n$ 上的可微函数 $f(x)$ 为凸函数的充要条件是:对所有的 $x, y \in \Omega$ 都有

$$f(y) \geq f(x) + (\nabla f(x))^T (y - x).$$

凸函数的充要条件I

定理3.6

定义在凸集 $\Omega \subset \mathbf{R}^n$ 上的可微函数 $f(x)$ 为凸函数的充要条件是:对所有的 $x, y \in \Omega$ 都有

$$f(y) \geq f(x) + (\nabla f(x))^T (y - x).$$

证明.

主要利用一阶Taylor公式

$$\begin{aligned} f(\lambda y + (1 - \lambda)x) &= f(x + \lambda(y - x)) \\ &= f(x) + \lambda(\nabla f(x))^T (y - x) + o(\lambda\|y - x\|) \end{aligned}$$

其中 $\lambda \in (0, 1)$.



凸函数的充要条件II

定理3.7

设 $\Omega \subset \mathbf{R}^n$ 为含有内点的凸集, $f(x) \in C^2$, 则 $f(x)$ 在 Ω 上为凸函数的充要条件是: $f(x)$ 的Hesse矩阵 $F(x) = \nabla^2 f(x)$ 在整个 Ω 上是半正定的.

凸函数的充要条件II

定理3.7

设 $\Omega \subset \mathbf{R}^n$ 为含有内点的凸集, $f(x) \in C^2$,则 $f(x)$ 在 Ω 上为凸函数的充要条件是: $f(x)$ 的Hesse矩阵 $F(x) = \nabla^2 f(x)$ 在整个 Ω 上是半正定的.

证明.

由定理3.6和二阶Taylor公式

$$\begin{aligned} f(y) = & f(x) + (\nabla f(x))^T (y - x) \\ & + \frac{1}{2} (y - x)^T F(x + \alpha(y - x)) (y - x) \end{aligned}$$

其中 $\alpha \in (0, 1)$.



严格凸函数的充分条件

定理3.8

设 $\Omega \subset \mathbf{R}^n$ 为非空开凸集, $f(x) \in C^2$, 若 $\nabla^2 f(x)$ 在 Ω 上处处正定, 则 $f(x)$ 在 Ω 上为严格凸函数.

$\nabla^2 f(x)$ 在 Ω 上处处正定是严格凸函数的充分非必要条件. 反例 $f(x) = x^4$.

严格凸函数的充分条件

定理3.8

设 $\Omega \subset \mathbf{R}^n$ 为非空开凸集, $f(x) \in C^2$, 若 $\nabla^2 f(x)$ 在 Ω 上处处正定, 则 $f(x)$ 在 Ω 上为严格凸函数.

$\nabla^2 f(x)$ 在 Ω 上处处正定是严格凸函数的充分非必要条件. 反例 $f(x) = x^4$.

例3.3

讨论 $f(x) = 5x_1^2 - 6x_1x_2 + 5x_2^2$ 在凸集 $\Omega \subset \mathbf{R}^n$ 上是否为严格凸函数.

严格凸函数的充分条件

定理3.8

设 $\Omega \subset \mathbf{R}^n$ 为非空开凸集, $f(x) \in C^2$, 若 $\nabla^2 f(x)$ 在 Ω 上处处正定, 则 $f(x)$ 在 Ω 上为严格凸函数.

$\nabla^2 f(x)$ 在 Ω 上处处正定是严格凸函数的充分非必要条件. 反例 $f(x) = x^4$.

例3.3

讨论 $f(x) = 5x_1^2 - 6x_1x_2 + 5x_2^2$ 在凸集 $\Omega \subset \mathbf{R}^n$ 上是否为严格凸函数.

解:

$F(x) = \nabla^2 f(x) = \begin{pmatrix} 10 & -6 \\ -6 & 10 \end{pmatrix}$ 中所有的顺序主子式为

$$10 > 0, \quad \begin{vmatrix} 10 & -6 \\ -6 & 10 \end{vmatrix} = 64 > 0.$$

所以 $F(x)$ 处处正定, 因此 $f(x)$ 为严格凸函数.

例3.4

讨论 $f(x) = \frac{1}{2}x^T Ax + b^T x + c$, 其中 A 为对称阵, $b = (b_1, b_2, \dots, b_n)^T$ 为给定向量, c 为常数, 则

- (1) 当 A 为半正定时 (记为 $A \geq 0$), $f(x)$ 为凸函数.
- (2) 当 A 为正定时 (记为 $A > 0$), $f(x)$ 为严格凸函数.

例3.4

讨论 $f(x) = \frac{1}{2}x^T Ax + b^T x + c$, 其中 A 为对称阵, $b = (b_1, b_2, \dots, b_n)^T$ 为给定向量, c 为常数, 则

- (1) 当 A 为半正定时(记为 $A \geq 0$), $f(x)$ 为凸函数.
- (2) 当 A 为正定时(记为 $A > 0$), $f(x)$ 为严格凸函数.

解:

因为 $F(x) = \nabla^2 f(x) = A$, 由定理3.7和定理3.8即得到结论。

1.3.3 凸规划

考虑如下的非线性规划问题:

$$\begin{array}{ll}\min & f(x) \\ \text{s.t.} & g_i(x) \leq 0, \quad i = 1, 2, \dots, m, \\ & h_j(x) = 0, \quad j = m+1, m+2, \dots, p.\end{array} \quad (3-7)$$

因为

$$h_i(x) = 0 \iff h_i(x) \leq 0, \text{ 且 } -h_i(x) \leq 0.$$

因此,不失一般性,我们可以考虑仅包含不等式约束的优化问题:

$$\begin{array}{ll}\min & f(x) \\ \text{s.t.} & g_i(x) \leq 0, \quad i = 1, 2, \dots, l.\end{array} \quad (3-8)$$

定义3.6

在问题(3-8)中,若 $f(x), g_i(x) (i = 1, 2, \dots, l)$ 均为可行集 R 上的凸函数,则称这样的问题为凸规划问题.

定义3.6

在问题(3-8)中,若 $f(x), g_i(x) (i = 1, 2, \dots, l)$ 均为可行集 R 上的凸函数,则称这样的问题为凸规划问题.

定理3.9

凸规划问题(3-8)的可行集 R 是凸集.

定理3.10

对于凸规划问题(3-8), 目标函数 $f(x)$ 的任一局部极小点都是 $f(x)$ 在非空可行集 R 上的全局极小点.

定理3.10

对于凸规划问题(3-8), 目标函数 $f(x)$ 的任一局部极小点都是 $f(x)$ 在非空可行集 R 上的全局极小点.

定理3.11

对于凸规划问题(3-8), 若 $f(x)$ 在非空可行集 R 上是严格凸函数, 则问题(3-8)的全局极小点是唯一的.

定义3.7

设 $\Omega \subset \mathbf{R}^n$ 为非空凸集, $f : \Omega \rightarrow \mathbf{R}^1$,若 $\forall x, y \in \Omega$,均有

$$f(\lambda x + (1 - \lambda)y) \leq \max\{f(x), f(y)\}, \forall \lambda \in (0, 1)$$

成立,则称 $f(x)$ 在 Ω 上为拟凸函数.

定义3.7

设 $\Omega \subset \mathbf{R}^n$ 为非空凸集, $f : \Omega \rightarrow \mathbf{R}^1$, 若 $\forall x, y \in \Omega$, 均有

$$f(\lambda x + (1 - \lambda)y) \leq \max\{f(x), f(y)\}, \forall \lambda \in (0, 1)$$

成立, 则称 $f(x)$ 在 Ω 上为拟凸函数.

- 严格拟凸函数, $\forall x, y \in \Omega, f(x) \neq f(y), <$
- 拟凹函数, $-f$ 拟凸
- 严格拟凹函数, $-f$ 严格拟凸

严格拟凸函数不一定是拟凸函数; 凸函数一定是拟凸函数.

定义3.7

设 $\Omega \subset \mathbf{R}^n$ 为非空开凸集, $f : \Omega \rightarrow \mathbf{R}^1$ 为可微函数,如果对于

$$\nabla f(x^1)^T(x^1 - x^2) \leq 0, \forall x^1, x^2 \in \Omega$$

必有 $f(x^1) \leq f(x^2)$,则称 $f(x)$ 在 Ω 上为伪凸函数.

伪凸函数

定义3.7

设 $\Omega \subset \mathbf{R}^n$ 为非空开凸集, $f : \Omega \rightarrow \mathbf{R}^1$ 为可微函数,如果对于

$$\nabla f(x^1)^T(x^1 - x^2) \leq 0, \forall x^1, x^2 \in \Omega$$

必有 $f(x^1) \leq f(x^2)$,则称 $f(x)$ 在 Ω 上为伪凸函数.

- 严格伪凸函数, $\nabla f(x^1)^T(x^1 - x^2) < 0, \forall x^1, x^2 \in \Omega, x^1 \neq x^2$
- 伪凹函数, $-f$ 伪凸
- 严格伪凹函数, $-f$ 严格伪凸

可微的凸函数是伪凸函数; 严格伪凸函数是伪凸函数; 可微的伪凸函数是严格拟凸函数, 也是拟凸函数.

广义凸规划

若问题(3-8)的可行集 R 是凸集, $f(x)$ 是 R 上的(严格)拟凸函数或(严格)伪凸函数, 则称(3-8)为广义凸规划问题.

广义凸规划

若问题(3-8)的可行集 R 是凸集, $f(x)$ 是 R 上的(严格)拟凸函数或(严格)伪凸函数, 则称(3-8)为广义凸规划问题.

定理3.15

设(3-8)的可行集 R 是凸集, $f(x)$ 是 R 上的严格拟凸函数, 则广义凸规划(3-8)的任一局部最优解 x^* 是全局最优解.

广义凸规划

若问题(3-8)的可行集 R 是凸集, $f(x)$ 是 R 上的(严格)拟凸函数或(严格)伪凸函数, 则称(3-8)为广义凸规划问题.

定理3.15

设(3-8)的可行集 R 是凸集, $f(x)$ 是 R 上的严格拟凸函数, 则广义凸规划(3-8)的任一局部最优解 x^* 是全局最优解.

定理3.16

设(3-8)的可行集 R 是开凸集, $f(x)$ 是 R 上的伪凸函数, $x^* \in R$, 若 $\nabla f(x^*) = 0$, 则 x^* 是(3-8)的全局最优解.