



DUT

大连理工大学

DALIAN UNIVERSITY OF TECHNOLOGY

第4章 逐次逼近法

4.3 计算特征值的幂法



在很多工程技术和科学计算中，经常会碰到计算矩阵的特征问题。设 $A \in \mathbf{R}^{n \times n}$ ，矩阵A的特征问题是求数 λ 和非零向量 \mathbf{x} ，使得

$$A\mathbf{x} = \lambda\mathbf{x}, \quad (4-32)$$

在线性代数中曾经计算过低阶矩阵的特征问题，即由 n 次代数方程

$$f(\lambda) = \det(\lambda I - A) = 0 \quad (4-33)$$

中，求出 (4-33) 的根 λ_i ，即为A的特征值，再从线性方程组

$$(\lambda_i I - A)\mathbf{x} = \mathbf{0} \quad (4-34)$$

中求出 $\mathbf{x}^{(i)}$ ，即为 λ_i 的关于的特征向量 $\mathbf{x}^{(i)}$ 。 λ_i 和 $\mathbf{x}^{(i)}$ 称为A的**特征对**。

4.3.1 幂法

用解非线性方程和解线性方程组的方法求矩阵特征问题, 一般情况计算量很大。因此, 须考虑用其他方法计算A的特征对。在不少工程实际中往往需要求矩阵A绝对值(模)最大或最小的特征值。**幂法**就是求这种特征值与相应的特征向量的方法。

矩阵A绝对值最大的特征值称**主特征值**。设A的特征值和对应的特征向量分别为

$$\lambda_1, \lambda_2, \dots, \lambda_n \quad \mathbf{x}^{(1)}, \mathbf{x}^{(2)}, \dots, \mathbf{x}^{(n)}$$

且 $|\lambda_1| > |\lambda_2| \geq |\lambda_3| \geq \dots \geq |\lambda_n|$; $\mathbf{x}^{(1)}, \mathbf{x}^{(2)}, \dots, \mathbf{x}^{(n)}$ 构成A的线性无关特征向量组。 则对任一n维向量 $\mathbf{v}^{(0)}$ 均可表示成

和

$$\mathbf{v}^{(0)} = \alpha_1 \mathbf{x}^{(1)} + \alpha_2 \mathbf{x}^{(2)} + \dots + \alpha_n \mathbf{x}^{(n)} \quad (\alpha_1 \neq 0)$$

$$\mathbf{A}\mathbf{v}^{(0)} = \alpha_1 \mathbf{A}\mathbf{x}^{(1)} + \alpha_2 \mathbf{A}\mathbf{x}^{(2)} + \dots + \alpha_n \mathbf{A}\mathbf{x}^{(n)}$$

$$\begin{aligned}\mathbf{A}\mathbf{v}^{(0)} &= \alpha_1\mathbf{A}\mathbf{x}^{(1)} + \alpha_2\mathbf{A}\mathbf{x}^{(2)} + \cdots + \alpha_n\mathbf{A}\mathbf{x}^{(n)} \\ &= \alpha_1\lambda_1\mathbf{x}^{(1)} + \alpha_2\lambda_2\mathbf{x}^{(2)} + \cdots + \alpha_n\lambda_n\mathbf{x}^{(n)}\end{aligned}$$

$$\mathbf{A}^2\mathbf{v}^{(0)} = \alpha_1\lambda_1^2\mathbf{x}^{(1)} + \alpha_2\lambda_2^2\mathbf{x}^{(2)} + \cdots + \alpha_n\lambda_n^2\mathbf{x}^{(n)}$$

$$\vdots$$

$$\mathbf{A}^k\mathbf{v}^{(0)} = \alpha_1\lambda_1^k\mathbf{x}^{(1)} + \alpha_2\lambda_2^k\mathbf{x}^{(2)} + \cdots + \alpha_n\lambda_n^k\mathbf{x}^{(n)}$$

$$= \lambda_1^k \cdot \left[\alpha_1\mathbf{x}^{(1)} + \alpha_2\left(\frac{\lambda_2}{\lambda_1}\right)^k\mathbf{x}^{(2)} + \cdots + \alpha_n\left(\frac{\lambda_n}{\lambda_1}\right)^k\mathbf{x}^{(n)} \right]$$

则
$$\frac{\mathbf{A}^k\mathbf{v}^{(0)}}{\lambda_1^k} = \alpha_1\mathbf{x}^{(1)} + \alpha_2\left(\frac{\lambda_2}{\lambda_1}\right)^k\mathbf{x}^{(2)} + \cdots + \alpha_n\left(\frac{\lambda_n}{\lambda_1}\right)^k\mathbf{x}^{(n)}$$

因为 $\left|\frac{\lambda_i}{\lambda_1}\right| < 1, (i=2, 3, \cdots, n)$, 所以

$$\lim_{k \rightarrow \infty} \frac{\mathbf{A}^k\mathbf{v}^{(0)}}{\lambda_1^k} = \alpha_1\mathbf{x}^{(1)}$$

(4-35)

$$\lim_{k \rightarrow \infty} \frac{\mathbf{A}^k \mathbf{v}^{(0)}}{\lambda_1^k} = \alpha_1 \mathbf{x}^{(1)} \quad (4-35)$$

(4-35)说明 $\frac{\mathbf{A}^k \mathbf{v}^{(0)}}{\lambda_1^k}$ 随着的 k 无限增大, 趋于 \mathbf{A} 的主特征值对应的特征向量 $\mathbf{x}^{(1)}$ (特征向量乘一个不为0的常数 α 特征向量后, 仍为原特征值对应的特征向量)。

若令 $\mathbf{v}^{(k)} = \mathbf{A}^k \mathbf{v}^{(0)}$, 则 $\mathbf{v}^{(k)} \approx \lambda_1^k \alpha_1 \mathbf{x}^{(1)} = (\alpha_1 \lambda_1^k) \mathbf{x}^{(1)}$

故 $\mathbf{v}^{(k)}$ 也可作为 λ_1 对应的近似特征向量。 又因为

$$\frac{v_i^{(k)}}{v_i^{(k-1)}} = \frac{(\mathbf{A}^k \mathbf{v}^{(0)})_i}{(\mathbf{A}^{k-1} \mathbf{v}^{(0)})_i} = \frac{\left[\lambda_1^k \left(\alpha_1 \mathbf{x}^{(1)} + \alpha_2 \left(\frac{\lambda_2}{\lambda_1} \right)^k \mathbf{x}^{(2)} + \cdots + \alpha_n \left(\frac{\lambda_n}{\lambda_1} \right)^k \mathbf{x}^{(n)} \right) \right]_i}{\left[\lambda_1^{k-1} \left(\alpha_1 \mathbf{x}^{(1)} + \alpha_2 \left(\frac{\lambda_2}{\lambda_1} \right)^{k-1} \mathbf{x}^{(2)} + \cdots + \alpha_n \left(\frac{\lambda_n}{\lambda_1} \right)^{k-1} \mathbf{x}^{(n)} \right) \right]_i}$$

$$= \lambda_1 \frac{\left[\alpha_1 \mathbf{x}^{(1)} + \alpha_2 \left(\frac{\lambda_2}{\lambda_1} \right)^k \mathbf{x}^{(2)} + \cdots + \alpha_n \left(\frac{\lambda_n}{\lambda_1} \right)^k \mathbf{x}^{(n)} \right]_i}{\left[\alpha_1 \mathbf{x}^{(1)} + \alpha_2 \left(\frac{\lambda_2}{\lambda_1} \right)^{k-1} \mathbf{x}^{(2)} + \cdots + \alpha_n \left(\frac{\lambda_n}{\lambda_1} \right)^{k-1} \mathbf{x}^{(n)} \right]_i}$$

其中 $\mathbf{v}^{(k)} = (v_1^{(k)}, v_2^{(k)}, \dots, v_n^{(k)})^T$ 。所以

$$\lim_{k \rightarrow \infty} \frac{v_i^{(k)}}{v_i^{(k-1)}} = \lambda_1 \quad (4-36)$$

(4-36) 表明, 序列 $\frac{v_i^{(k)}}{v_i^{(k-1)}} (k=1, 2, \dots)$ 收敛于A的主特征值 λ_1 , 其收敛速度取决于比值 $r = \left| \frac{\lambda_2}{\lambda_1} \right|$ 的大小, r 越小, 收敛速度越快, 如果 $r \approx 1$, 则收敛速度就很慢, 需要采用加速技术。

综上所述, 可得如下定理

定理4.8 若矩阵A具有n个线性无关的特征向量

$$\mathbf{x}^{(1)}, \mathbf{x}^{(2)}, \dots, \mathbf{x}^{(n)}$$

且对应的特征值满足 $|\lambda_1| > |\lambda_2| \geq |\lambda_3| \geq \dots \geq |\lambda_n|$, 则取 $\mathbf{v}^{(0)} \neq 0$, 经使用

$$\mathbf{v}^{(k)} = \mathbf{A}^k \mathbf{v}^{(0)} \quad k = 1, 2, \dots \quad (4-37)$$

迭代计算可得

$$1) \quad \mathbf{v}^{(k)} = \alpha_1 \lambda_1^k \mathbf{x}^{(1)} \quad (\alpha_1 \neq 0) \quad (4-38)$$

$$2) \quad \frac{v_i^{(k)}}{v_i^{(k-1)}} \approx \lambda_1 \quad (4-39)$$

利用 (4-37)、(4-38)、(4-39) 计算A的主特征值 λ_1 , 及其对应的特征向量 $\mathbf{x}^{(1)}$ 的方法, 称为**幂法**。其中 $(\lambda_1, \mathbf{x}^{(1)})$ 也称**极端特征对**。



在使用幂法法时还应注意:

1) 由于在取初始向量 $\mathbf{v}^{(0)}$ 时, $\mathbf{x}^{(1)}, \mathbf{x}^{(2)}, \dots, \mathbf{x}^{(n)}$ 事先不知, 可能使 $\mathbf{v}^{(0)} = \alpha_1 \mathbf{x}^{(1)} + \alpha_2 \mathbf{x}^{(2)} + \dots + \alpha_n \mathbf{x}^{(n)}$ 中的 $\alpha_1 = 0$ 。从理论上讲, 此时必须换初始向量 $\mathbf{v}^{(0)}$, 否则算不出 $\mathbf{x}^{(1)}$, 但是在实际计算时, 由于舍入误差的影响, 可能经几步迭代后得到

$$\mathbf{v}^{(t)} = A^t \mathbf{v}^{(0)} = \beta_1 \mathbf{x}^{(1)} + \beta_2 \mathbf{x}^{(2)} + \dots + \beta_n \mathbf{x}^{(n)}$$

其中 $\beta_1 \neq 0$, 这样继续算下去仍可算出 $\mathbf{x}^{(1)}$ 的近似值, 但是迭代次数就要增加, 如果发现收敛速度很慢, 可以更换初始向量 $\mathbf{v}^{(0)}$ 后再进行迭代计算。

$$\boldsymbol{v}^{(k)} = \alpha_1 \lambda_1^k \boldsymbol{x}^{(1)} \quad (\alpha_1 \neq 0) \quad (4-38)$$

2) 从 $\boldsymbol{v}^{(k)} = \alpha_1 \lambda_1^k \boldsymbol{x}^{(1)}$ 中易知, 当 $|\lambda_1| > 1$ (或 $|\lambda_1| < 1$) 时, 数值计算将产生“溢出”, 即计算 $\boldsymbol{v}^{(k)}$, 当 $k \rightarrow \infty$ 时, $\boldsymbol{v}^{(k)}$ 中的非零分量将趋于零或无穷大。为了避免这种现象的产生, 需要将由 (4-38) 式每次算得的向量 \boldsymbol{v} 进行规范化, 即在向量上除以一个常数。

为了方便起见, 除数可取该向量绝对值最大的分量, 并记为 $\max(\boldsymbol{v})$ 。

若 $\boldsymbol{v} = (v_1, v_2, \dots, v_n)^T$ 且 $|v_k| = \max_{1 \leq i \leq n} |v_i|$

则 $\max(\boldsymbol{v}) = v_k$

令
$$\boldsymbol{u} = \frac{\boldsymbol{v}}{\max(\boldsymbol{v})} = \left(\frac{v_1}{v_k}, \frac{v_2}{v_k}, \dots, \frac{v_{k-1}}{v_k}, 1, \dots, \frac{v_n}{v_k} \right)^T$$

如此规范后的向量 \boldsymbol{v} , 其绝对值最大的分量的值为1。

于是幂法可作如下表达：

(1) 取初始向量 $\mathbf{v}^{(0)} \neq \mathbf{0}$, 且 $\alpha_1 \neq 0$, 并令 $\mathbf{u}^{(0)} = \mathbf{v}^{(0)}$

(2) $\mathbf{v}^{(1)} = \mathbf{A}\mathbf{v}^{(0)} = \mathbf{A}\mathbf{u}^{(0)}$

$$\mathbf{u}^{(1)} = \frac{\mathbf{v}^{(1)}}{\max(\mathbf{v}^{(1)})} = \frac{\mathbf{A}\mathbf{v}^{(0)}}{\max(\mathbf{A}\mathbf{v}^{(0)})}$$

(3) $\mathbf{v}^{(2)} = \mathbf{A}\mathbf{u}^{(1)} = \frac{\mathbf{A}^2\mathbf{v}^{(0)}}{\max(\mathbf{A}\mathbf{v}^{(0)})} = \frac{\mathbf{A}\mathbf{v}^{(1)}}{\max(\mathbf{A}\mathbf{v}^{(0)})}$

$$\mathbf{u}^{(2)} = \frac{\mathbf{v}^{(2)}}{\max(\mathbf{v}^{(2)})} = \frac{\mathbf{A}^2\mathbf{v}^{(0)}}{\max(\mathbf{A}^2\mathbf{v}^{(0)})}$$

$$(4) \quad \begin{cases} \mathbf{v}^{(k)} = \mathbf{A}\mathbf{u}^{(k-1)} = \frac{\mathbf{A}^k\mathbf{v}^{(0)}}{\max(\mathbf{A}^{k-1}\mathbf{v}^{(0)})} \\ \mathbf{u}^{(k)} = \frac{\mathbf{v}^{(k)}}{\max(\mathbf{v}^{(k)})} = \frac{\mathbf{A}^k\mathbf{v}^{(0)}}{\max(\mathbf{A}^k\mathbf{v}^{(0)})} \\ k = 3, 4, \dots \end{cases} \quad (4-40)$$

因为

$$\begin{aligned}\mathbf{u}^{(k)} &= \frac{\mathbf{A}^k \mathbf{v}^{(0)}}{\max(\mathbf{A}^k \mathbf{v}^{(0)})} = \frac{\lambda_1^k \left[\alpha_1 \mathbf{x}^{(1)} + \cdots + \alpha_n \left(\frac{\lambda_n}{\lambda_1} \right)^k \mathbf{x}^{(n)} \right]}{\max \left(\lambda_1^k \left[\alpha_1 \mathbf{x}^{(1)} + \cdots + \alpha_n \left(\frac{\lambda_n}{\lambda_1} \right)^k \mathbf{x}^{(n)} \right] \right)} \\ &= \frac{\left[\alpha_1 \mathbf{x}^{(1)} + \alpha_n \left(\frac{\lambda_2}{\lambda_1} \right)^k \mathbf{x}^{(2)} + \cdots + \alpha_n \left(\frac{\lambda_n}{\lambda_1} \right)^k \mathbf{x}^{(n)} \right]}{\max \left(\alpha_1 \mathbf{x}^{(1)} + \alpha_n \left(\frac{\lambda_2}{\lambda_1} \right)^k \mathbf{x}^{(2)} + \cdots + \alpha_n \left(\frac{\lambda_n}{\lambda_1} \right)^k \mathbf{x}^{(n)} \right)}\end{aligned}$$

所以

$$\lim_{k \rightarrow \infty} \mathbf{u}^{(k)} = \frac{\alpha_1 \mathbf{x}^{(1)}}{\max(\alpha_1 \mathbf{x}^{(1)})} = \frac{\mathbf{x}^{(1)}}{\max(\mathbf{x}^{(1)})}$$

又因为

$$\begin{aligned}\mathbf{v}^{(k)} &= \frac{\mathbf{A}^k \mathbf{v}^{(0)}}{\max(\mathbf{A}^{k-1} \mathbf{v}^{(0)})} = \frac{\lambda_1^k \left[\alpha_1 \mathbf{x}^{(1)} + \cdots + \alpha_n \left(\frac{\lambda_n}{\lambda_1} \right)^k \mathbf{x}^{(n)} \right]}{\lambda_1^{k-1} \max \left[\alpha_1 \mathbf{x}^{(1)} + \cdots + \alpha_n \left(\frac{\lambda_n}{\lambda_1} \right)^{k-1} \mathbf{x}^{(n)} \right]} \\ &= \lambda_1 \frac{\left[\alpha_1 \mathbf{x}^{(1)} + \alpha_2 \left(\frac{\lambda_2}{\lambda_1} \right)^k \mathbf{x}^{(2)} + \cdots + \alpha_n \left(\frac{\lambda_n}{\lambda_1} \right)^k \mathbf{x}^{(n)} \right]}{\max \left[\alpha_1 \mathbf{x}^{(1)} + \alpha_2 \left(\frac{\lambda_2}{\lambda_1} \right)^{k-1} \mathbf{x}^{(2)} + \cdots + \alpha_n \left(\frac{\lambda_n}{\lambda_1} \right)^{k-1} \mathbf{x}^{(n)} \right]}\end{aligned}$$

所以

$$\lim_{k \rightarrow \infty} \max(\mathbf{v}^{(k)}) = \lambda_1$$

故当 k 足够大时,

$$\mathbf{u}^{(k)} \approx \frac{\mathbf{x}^{(1)}}{\max(\mathbf{x}^{(1)})} \quad (4-41)$$

即 $\mathbf{u}^{(k)}$ 为主特征值对应的特征向量的近似向量。

$$\max(\mathbf{v}^{(k)}) \approx \lambda_1 \quad (4-42)$$

$\max(\mathbf{v}^{(k)})$ 为主特征值的近似值。

计算A的主特征值 λ_1 , 及其对应的特征向量 $\mathbf{x}^{(1)}$ 的幂法。

取初始向量 $\mathbf{v}^{(0)} \neq \mathbf{0}$, 且 $\alpha_1 \neq 0$, 并令 $\mathbf{u}^{(0)} = \mathbf{v}^{(0)}$

$$\begin{cases} \mathbf{v}^{(k)} = A\mathbf{u}^{(k-1)} = \frac{A^k \mathbf{v}^{(0)}}{\max(A^{k-1} \mathbf{v}^{(0)})} \\ \mathbf{u}^{(k)} = \frac{\mathbf{v}^{(k)}}{\max(\mathbf{v}^{(k)})} = \frac{A^k \mathbf{v}^{(0)}}{\max(A^k \mathbf{v}^{(0)})} \\ k = 1, 2, \dots \end{cases}$$

故当 k 足够大时

$$\mathbf{u}^{(k)} \approx \frac{\mathbf{x}^{(1)}}{\max(\mathbf{x}^{(1)})}$$

即 $\mathbf{u}^{(k)}$ 为主特征值对应的特征向量的近似向量。

$$\max(\mathbf{v}^{(k)}) \approx \lambda_1$$

$\max(\mathbf{v}^{(k)})$ 为主特征值的近似值。

例1 用幂法计算矩阵

$$A = \begin{pmatrix} 1.0 & 1.0 & 0.5 \\ 1.0 & 1.0 & 0.25 \\ 0.5 & 0.25 & 2.0 \end{pmatrix}$$

$$\mathbf{v}^{(k)} = A\mathbf{u}^{(k-1)} = \frac{A^k \mathbf{v}^{(0)}}{\max(A^{k-1} \mathbf{v}^{(0)})}$$

$$\mathbf{u}^{(k)} = \frac{\mathbf{v}^{(k)}}{\max(\mathbf{v}^{(k)})} = \frac{A^k \mathbf{v}^{(0)}}{\max(A^k \mathbf{v}^{(0)})}$$

的极端特征对。取 $\mathbf{v}^{(0)}=(1,1,1)^T$ 。 令 $\mathbf{u}^{(0)} = \mathbf{v}^{(0)}$

$$\mathbf{v}^{(1)} = A\mathbf{v}^{(0)} = \begin{pmatrix} 1.0 & 1.0 & 0.5 \\ 1.0 & 1.0 & 0.25 \\ 0.5 & 0.25 & 2.0 \end{pmatrix} \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix} = \begin{pmatrix} 2.5 \\ 2.25 \\ 2.75 \end{pmatrix} = A\mathbf{u}^{(0)}$$

$$\max(\mathbf{v}^{(1)}) = v_3^{(1)} = 2.7500,$$

$$\begin{aligned} \mathbf{u}^{(1)} &= \frac{\mathbf{v}^{(1)}}{\max(\mathbf{v}^{(1)})} = \frac{A\mathbf{v}^{(0)}}{\max(A\mathbf{v}^{(0)})} = \left(\frac{2.5}{2.75}, \frac{2.25}{2.75}, 1 \right)^T \\ &= (0.9091, 0.8182, 1)^T \end{aligned}$$

$$\begin{aligned}\mathbf{v}^{(2)} = \mathbf{A}\mathbf{u}^{(1)} &= \begin{pmatrix} 1.0 & 1.0 & 0.5 \\ 1.0 & 1.0 & 0.25 \\ 0.5 & 0.25 & 2.0 \end{pmatrix} \begin{pmatrix} 0.9091 \\ 0.8182 \\ 1 \end{pmatrix} \\ &= (2.2192, 1.9692, 2.6591)^T\end{aligned}$$

$$\max(\mathbf{v}^{(2)}) = v_3^{(2)} = 2.6591,$$

$$\begin{aligned}\mathbf{u}^{(2)} = \frac{\mathbf{v}^{(2)}}{\max(\mathbf{v}^{(2)})} &= \left(\frac{2.2192}{2.6591}, \frac{1.9692}{2.6591}, 1 \right)^T \\ &= (0.8346, 0.7406, 1)^T\end{aligned}$$

$$\begin{aligned}\mathbf{v}^{(3)} = \mathbf{A}\mathbf{u}^{(2)} &= \begin{pmatrix} 1.0 & 1.0 & 0.5 \\ 1.0 & 1.0 & 0.25 \\ 0.5 & 0.25 & 2.0 \end{pmatrix} \begin{pmatrix} 0.8346 \\ 0.7406 \\ 1 \end{pmatrix} \\ &= (2.0752, 1.8252, 2.6025)^T, \quad \max(\mathbf{v}^{(3)}) = v_3^{(3)} = 2.6025,\end{aligned}$$

$$\max(\mathbf{v}^{(3)}) = v_3^{(3)} = 2.6025,$$

$$\begin{aligned}\mathbf{u}^{(3)} &= \frac{\mathbf{v}^{(3)}}{\max(\mathbf{v}^{(3)})} = \left(\frac{2.0752}{2.6025}, \frac{1.8252}{2.6025}, 1.0000 \right)^T \\ &= (0.7974, 0.7013, 1.0000)^T\end{aligned}$$

$$\begin{aligned}\mathbf{v}^{(4)} = \mathbf{A}\mathbf{u}^{(3)} &= \begin{pmatrix} 1.0 & 1.0 & 0.5 \\ 1.0 & 1.0 & 0.25 \\ 0.5 & 0.25 & 2.0 \end{pmatrix} \begin{pmatrix} 0.7974 \\ 0.7013 \\ 1.0000 \end{pmatrix} \\ &= (1.9987, 1.7487, 2.5740)^T\end{aligned}$$

$$\max(\mathbf{v}^{(4)}) = v_3^{(4)} = 2.5740,$$

$$\begin{aligned}\mathbf{u}^{(4)} &= \frac{\mathbf{v}^{(4)}}{\max(\mathbf{v}^{(4)})} = \left(\frac{1.9987}{2.5740}, \frac{1.7487}{2.5740}, 1.0000 \right)^T \\ &= (0.7765, 0.6794, 1.0000)^T\end{aligned}$$

$$\mathbf{u}^{(4)} = (0.7765, 0.6794, 1.0000)^T$$

$$\begin{aligned}\mathbf{v}^{(5)} = \mathbf{A}\mathbf{u}^{(4)} &= \begin{pmatrix} 1.0 & 1.0 & 0.5 \\ 1.0 & 1.0 & 0.25 \\ 0.5 & 0.25 & 2.0 \end{pmatrix} \begin{pmatrix} 0.7765 \\ 0.6794 \\ 1.0000 \end{pmatrix} \\ &= (1.9559, 1.7059, 2.5582)^T\end{aligned}$$

$$\max(\mathbf{v}^{(5)}) = v_3^{(5)} = 2.5582,$$

$$\begin{aligned}\mathbf{u}^{(5)} = \frac{\mathbf{v}^{(5)}}{\max(\mathbf{v}^{(5)})} &= \left(\frac{1.9559}{2.5582}, \frac{1.7059}{2.5582}, 1.0000 \right)^T \\ &= (0.7646, 0.6668, 1.0000)^T\end{aligned}$$

结果见下表

k	$(\mathbf{u}^{(k)})^T$ (规范化向量)	$\max(\mathbf{v}^{(k)})$
1	(0.9091, 0.8182, 1)	2.750000
\vdots	\vdots	\vdots
5	(0.7651, 0.6674, 1)	2.558792
\vdots	\vdots	\vdots
10	(0.7494, 0.6508, 1)	2.538003
\vdots	\vdots	\vdots
15	(0.7483, 0.6497, 1)	2.536626
16	(0.7483, 0.6497, 1)	2.536584
17	(0.7483, 0.6497, 1)	2.536560
18	(0.7483, 0.6497, 1)	2.536546
19	(0.7483, 0.6497, 1)	2.536537
20	(0.7483, 0.6497, 1)	2.536532

$$\mathbf{A} = \begin{pmatrix} 1.0 & 1.0 & 0.5 \\ 1.0 & 1.0 & 0.25 \\ 0.5 & 0.25 & 2.0 \end{pmatrix}$$

主特征值的计算值为:

$$\lambda_1 \approx 2.536532$$

λ_1 对应的特征向量为:

$$\mathbf{x}^{(1)} \approx (0.7482, 0.6497, 1)^T$$

验证:

$$\mathbf{A}\mathbf{x}^{(1)} = \begin{pmatrix} 1.8979 \\ 1.6479 \\ 2.5365 \end{pmatrix}$$

$$\lambda_1 \mathbf{x}^{(1)} = \begin{pmatrix} 1.8976 \\ 1.6480 \\ 2.5365 \end{pmatrix}$$



如果矩阵A的特征值不满足假设

$$|\lambda_1| > |\lambda_2| \geq |\lambda_3| \geq \cdots \geq |\lambda_n|$$

此时幂法的收敛性分析就变得复杂，它可能产生如下几种情况

(1) $\lambda_1 = \lambda_2 = \cdots = \lambda_r$, 且 $|\lambda_1| > |\lambda_{r+1}|$

(2) $\lambda_1 = \lambda_2 = \cdots = \lambda_t$, $\lambda_{t+1} = \lambda_{t+2} = \cdots = \lambda_r = -\lambda_1$

且 $|\lambda_1| > |\lambda_{r+1}|$

(3) $\lambda_1 = \bar{\lambda}_2$, 且 $|\lambda_1| > |\lambda_3|$

只就(1)讨论。对于情况(1), 由于

$$\begin{aligned} \mathbf{A}^k \mathbf{v}^{(0)} &= \alpha_1 \lambda_1^k \mathbf{x}^{(1)} + \cdots + \alpha_r \lambda_1^k \mathbf{x}^{(r)} + \alpha_{r+1} \lambda_{r+1}^k \mathbf{x}^{(r+1)} + \cdots + \alpha_n \lambda_n^k \mathbf{x}^{(n)} \\ &= \lambda_1^k \left[\left(\alpha_1 \mathbf{x}^{(1)} + \cdots + \alpha_r \mathbf{x}^{(r)} \right) + \alpha_{r+1} \left(\frac{\lambda_{r+1}}{\lambda_1} \right)^k \mathbf{x}^{(r+1)} + \cdots + \alpha_n \left(\frac{\lambda_n}{\lambda_1} \right)^k \mathbf{x}^{(n)} \right] \\ \mathbf{u}^{(k)} &= \frac{\mathbf{A}^k \mathbf{v}^{(0)}}{\max(\mathbf{A}^k \mathbf{v}^{(0)})} \rightarrow \frac{\alpha_1 \mathbf{x}^{(1)} + \alpha_2 \mathbf{x}^{(2)} + \cdots + \alpha_r \mathbf{x}^{(r)}}{\max(\alpha_1 \mathbf{x}^{(1)} + \cdots + \alpha_r \mathbf{x}^{(r)})}, \quad \text{当 } k \rightarrow \infty \text{ 时。} \end{aligned}$$

$$\mathbf{v}^{(k)} = \frac{\mathbf{A}^k \mathbf{v}^{(0)}}{\max(\mathbf{A}^{k-1} \mathbf{v}^{(0)})} \rightarrow \lambda_1 \frac{\alpha_1 \mathbf{x}^{(1)} + \alpha_2 \mathbf{x}^{(2)} + \cdots + \alpha_r \mathbf{x}^{(r)}}{\max(\alpha_1 \mathbf{x}^{(1)} + \alpha_2 \mathbf{x}^{(2)} + \cdots + \alpha_r \mathbf{x}^{(r)})}$$

则当 $k \rightarrow \infty$ 时, $\max(\mathbf{v}^{(k)}) \rightarrow \lambda_1$ 。

故在情况(1), 若 $\mathbf{v}^{(0)}$ 的展开式中, 如果 $\alpha_1 \mathbf{x}^{(1)} + \alpha_2 \mathbf{x}^{(2)} + \cdots + \alpha_r \mathbf{x}^{(r)} \neq 0$

则矩阵 \mathbf{A} 的主特征值近似于 $\max(\mathbf{v}^{(k)})$, 对应的近似特征向量为

$$\frac{\alpha_1 \mathbf{x}^{(1)} + \alpha_2 \mathbf{x}^{(2)} + \cdots + \alpha_r \mathbf{x}^{(r)}}{\max(\alpha_1 \mathbf{x}^{(1)} + \alpha_2 \mathbf{x}^{(2)} + \cdots + \alpha_r \mathbf{x}^{(r)})}$$

情况(2)和(3)的分析较(1)要复杂, 读者可以参看[5]的第二章。



4.3.2 反幂法

如果对表达式

$$Ax = \lambda x$$

的两边乘 A^{-1} 后, 得到

$$A^{-1}Ax = Ix = \lambda A^{-1}x$$

故

$$A^{-1}x = \frac{1}{\lambda}x \quad (4-43)$$

(4-43)式说明 A 的绝对值最小的特征值的倒数为 A^{-1} 的主特征值。

因此,我们可以对 A^{-1} 用幂法求的绝对值最小的特征值,简称最小特征值.

计算A的主特征值 λ_1 , 及其对应的特征向量 $\mathbf{x}^{(1)}$ 的幂法。

取初始向量 $\mathbf{v}^{(0)} \neq \mathbf{0}$, 且 $\alpha_1 \neq 0$, 并令 $\mathbf{u}^{(0)} = \mathbf{v}^{(0)}$

$$\begin{cases} \mathbf{v}^{(k)} = A\mathbf{u}^{(k-1)} = \frac{A^k \mathbf{v}^{(0)}}{\max(A^{k-1} \mathbf{v}^{(0)})} \\ \mathbf{u}^{(k)} = \frac{\mathbf{v}^{(k)}}{\max(\mathbf{v}^{(k)})} = \frac{A^k \mathbf{v}^{(0)}}{\max(A^k \mathbf{v}^{(0)})} \\ k = 1, 2, \dots \end{cases} \quad (4-40)$$

故当 k 足够大时

$$\mathbf{u}^{(k)} \approx \frac{\mathbf{x}^{(1)}}{\max(\mathbf{x}^{(1)})}$$

即 $\mathbf{u}^{(k)}$ 为主特征值对应的特征向量的近似向量。

$$\max(\mathbf{v}^{(k)}) \approx \lambda_1$$

$\max(\mathbf{v}^{(k)})$ 为主特征值的近似值。

任取初始向量 $\mathbf{v}^{(0)}=\mathbf{u}^{(0)}$ ，使用幂法（4-40），得到迭代格式

$$\begin{cases} \mathbf{v}^{(k)} = \mathbf{A}^{-1} \mathbf{u}^{(k-1)} \\ \mathbf{u}^{(k)} = \frac{\mathbf{v}^{(k)}}{\max(\mathbf{v}^{(k)})} \end{cases} \quad k = 1, 2, \dots \quad (4-44)$$

（4-44）称为反幂法，其收敛速度取决于

$$r = \frac{\left| \frac{1}{\lambda_{n-1}} \right|}{\left| \frac{1}{\lambda_n} \right|} = \left| \frac{\lambda_n}{\lambda_{n-1}} \right|$$

在反幂法（4-44）中需要求 \mathbf{A} 的逆矩阵 \mathbf{A}^{-1} ，为了避免求 \mathbf{A}^{-1} ，可以通过解线性方程组

$$A\mathbf{v}^{(k)} = \mathbf{u}^{(k-1)}$$

的方法求出 $\mathbf{v}^{(k)}$ 。由于需要反复求解以 A 系数矩阵的方程组，所以可先对 A 进行三角分解 $A=LU$ 后，求解三角方程组，即求解

$$\begin{cases} L\mathbf{y}^{(k)} = \mathbf{v}^{(k-1)} \\ U\mathbf{v}^{(k)} = \mathbf{y}^{(k)} \end{cases}$$

其中 L, U 分别为下、上三角阵。

取初始向量 $\mathbf{u}^{(0)} \neq \mathbf{0}$ ，由迭代格式

$$\begin{cases} A\mathbf{v}^{(k)} = LU\mathbf{v}^{(k)} = \mathbf{u}^{(k-1)} \\ \mathbf{u}^{(k)} = \frac{\mathbf{v}^{(k)}}{\max(\mathbf{v}^{(k)})} \quad k = 1, 2, \dots \end{cases} \quad (4-45)$$

计算出的绝对值最小的特征值 λ_n 和对应的特征向量 $\mathbf{x}^{(n)}$ ，
 $(\lambda_n, \mathbf{x}^{(n)})$ 也称**极端特征对**。



DUT

大连理工大学

DALIAN UNIVERSITY OF TECHNOLOGY

当非奇异矩阵 A 有 n 个线性无关的特征向量

$$\mathbf{x}^{(1)}, \mathbf{x}^{(2)}, \dots, \mathbf{x}^{(n)}$$

且对应的特征值满足

$$|\lambda_1| \geq |\lambda_2| \geq \dots |\lambda_{n-1}| > |\lambda_n| > 0$$

则对于非零初始向量 $\mathbf{v}^{(0)} = \mathbf{u}^{(0)} \neq \mathbf{0}$ ($\alpha_n \neq 0$), 由反幂法(4-45)求出

$\mathbf{v}^{(k)}, \mathbf{u}^{(k)}$, 当 k 足够大时,

$$\mathbf{u}^{(k)} \approx \frac{\mathbf{v}^{(n)}}{\max(\mathbf{v}^{(n)})}, \quad \lambda_n \approx \frac{1}{\max(\mathbf{v}^{(k)})}$$

其中 $\frac{1}{\max(\mathbf{v}^{(k)})}$ 和 $\mathbf{v}^{(k)}$ 分别为 A 的最小特征值和对应的特征向量

的近似(计算)值。

由受到反幂法启发, 如果知道矩阵 A 的某个特征值 λ_i 的近似值 p , 或由某种方法求出特征值 λ_i 的近似值 p , 需要提高精度,

此时若有
$$|\lambda_i - p| < |\lambda_j - p| \quad i \neq j \quad (4-46)$$

由于
$$(A - pI)\mathbf{x}^{(i)} = A\mathbf{x}^{(i)} - p\mathbf{x}^{(i)} = (\lambda_i - p)\mathbf{x}^{(i)}$$

故若 $(A - pI)^{-1}$ 存在, 则

$$(A - pI)^{-1} \mathbf{x}^{(i)} = \frac{1}{\lambda_i - p} \mathbf{x}^{(i)} \quad (4-47)$$

从 (4-46) 和 (4-47) 知, $\frac{1}{\lambda_i - p}$ 是 $(A - pI)^{-1}$ 的主特征值。

于是使用反幂法
$$\begin{cases} (A - pI)\mathbf{v}^{(k)} = \mathbf{u}^{(k-1)} \\ \mathbf{u}^{(k)} = \frac{\mathbf{v}^{(k)}}{\max(\mathbf{v}^{(k)})} \quad k = 1, 2, \dots \end{cases}$$

求出 $\mathbf{v}^{(k)}, \mathbf{u}^{(k)}$, 当 k 足够大时,

$$\mathbf{u}^{(k)} \approx \frac{\mathbf{x}^{(i)}}{\max(\mathbf{x}^{(i)})}, \quad \max(\mathbf{v}^{(k)}) \approx \frac{1}{\lambda_i - P}$$

即

$$\lambda_i \approx p + \frac{1}{\max(\mathbf{v}^{(k)})} \quad (4-50)$$

(4-49) 和 (4-50) 分别为A的第*i* 特征向量和对应的特征值的近似(计算)值, 此法为原点位移的反幂法。

与反幂法一样, 为了节省工作量, 应先对 $(A - pI)$ 进行三角分解, 即

$$A - pI = LU$$

求 $\mathbf{v}^{(k)}$ 求时, 相当于解两个三角方程组

$$\begin{cases} L\mathbf{y}^{(k)} = \mathbf{v}^{(k-1)} \\ U\mathbf{v}^{(k)} = \mathbf{y}^{(k)} \end{cases}$$

因此反幂法可以写成



$$\begin{cases} Ly^{(k)} = u^{(k-1)} \\ Uv^{(k)} = y^{(k)} \\ u^{(k)} = \frac{v^{(k)}}{\max(v^{(k)})} \end{cases} \quad k = 1, 2, \dots \quad (4-51)$$

如果 LU 分解的计算精度不够时，可以采用列主元三角分解，即

$$PA = LU \quad (P(A - pI) = LU)$$

此时，应将（4-51）的第一式改为

$$Ly^{(k)} = Pu^{(k-1)}$$

其中 P 为排列阵。

练习 设 $A = \begin{pmatrix} -1 & 2 & 1 \\ 2 & -4 & 1 \\ 1 & 1 & -6 \end{pmatrix}$

有一近似特征值 $\tilde{\lambda}_j = -6.42$ ，用反幂法求对应的特征向量，并改进近似特征值的精度。

解 对矩阵 $A - \tilde{\lambda}_j \mathbf{I} = A + 6.42\mathbf{I}$ 作三角分解，得

$$A + 6.42\mathbf{I} = \mathbf{LU} = \begin{pmatrix} 1 & 0 & 0 \\ 0.369003 & 1 & 0 \\ 0.184503 & 0.375148 & 1 \end{pmatrix} \begin{pmatrix} 5.42 & 3 & 1 \\ 0 & 1.681993 & 0.630993 \\ 0 & 0 & -1.21884 \times 10^{-3} \end{pmatrix}$$

利用公式 (4-51)

$$\mathbf{L}\mathbf{y}^{(k)} = \mathbf{u}^{(k-1)}, \quad \mathbf{U}\mathbf{v}^{(k)} = \mathbf{y}^{(k)}, \quad \mathbf{u}^{(k)} = \frac{\mathbf{v}^{(k)}}{\max(\mathbf{v}^{(k)})}, \quad k = 1, 2, \dots$$

$$\text{取 } \mathbf{u}^{(0)} = (1, 1, 1)^T, \quad \text{则 } \mathbf{y}^{(1)} = (1, 0.631000, 0.578779)^T,$$

$$\mathbf{v}^{(1)} = (37.764, 308.38912, -820.446848)^T, \quad \max(\mathbf{v}^{(1)}) = -820.446848$$

$$L\mathbf{y}^{(k)} = \mathbf{u}^{(k-1)}, \quad U\mathbf{v}^{(k)} = \mathbf{y}^{(k)}, \quad \mathbf{u}^{(k)} = \frac{\mathbf{v}^{(k)}}{\max(\mathbf{v}^{(k)})}, \quad k = 1, 2, \dots$$

$$\mathbf{u}^{(1)} = \frac{\mathbf{v}^{(1)}}{\max(\mathbf{v}^{(1)})} = (-0.046029, -0.375871, 1)^T,$$

$$\mathbf{y}^{(2)} = (-0.046029, -0.358886, 1.143128)^T,$$

$$\mathbf{v}^{(2)} = (43.279655, 351.627002, -937.875765)^T,$$

$$\max(\mathbf{v}^{(2)}) = -937.875765$$

$$\mathbf{u}^{(2)} = \frac{\mathbf{v}^{(2)}}{\max(\mathbf{v}^{(2)})} = (-0.046147, -0.374918, 1)^T,$$

由于 $\mathbf{u}^{(1)}$ 与 $\mathbf{u}^{(2)}$ 对应的分量近似相等, $\|\mathbf{u}^{(2)} - \mathbf{u}^{(1)}\|_{\infty} = 0.000953 \leq \frac{1}{2} \times 10^{-2}$

故A的特征值为: $\lambda_j = -6.42 + \frac{1}{\max(\mathbf{v}^{(2)})} \approx -6.42107$

对应的特征向量为: $\mathbf{u}^{(3)} = (-0.046147, -0.374918, 1)^T$ 。



DUT

大连理工大学

DALIAN UNIVERSITY OF TECHNOLOGY

THE END