



DUT

大连理工大学

DALIAN UNIVERSITY OF TECHNOLOGY

第4章 逐次逼近法

4.5 共轭梯度法

4.5 共轭梯度法

共轭梯度法 (conjugate gradient method, CG) 是以共轭方向 (conjugate direction) 作为搜索方向的一类算法。

共轭梯度法是由Hesteness和Stiefel于1952年为求解线性方程组而提出的。后来用于求解无约束最优化问题，它是一种重要的数学优化方法。

设线性方程组：

$$Ax = b \quad (4-62)$$

其中 A 为 n 阶对称正定矩阵， $b \in \mathbf{R}^n$ ， $x \in \mathbf{R}^n$ 为待求向量。

考察二次函数 $\varphi(x): \mathbf{R}^n \rightarrow \mathbf{R}$

$$\varphi(x) = \frac{1}{2}(Ax, x) - (b, x) = \frac{1}{2} \sum_{j=1}^n \left(\sum_{i=1}^n a_{ij} x_i \right) x_j - \sum_{j=1}^n b_j x_j$$

则有

定理4.9 x^* 是 $Ax=b$ 的解 (A 为对称正定矩阵) 的充分必要条件

为 x^* 满足
$$\varphi(x^*) = \min_{x \in \mathbb{R}^n} \varphi(x)$$

证 必要性 设 $Ax^*=b$, 取 $x=x^*+tp$, 其中 $t \in \mathbb{R}, 0 \neq p \in \mathbb{R}^n$, 则

$$\begin{aligned}\varphi(x^* + tp) &= \frac{1}{2} (A(x^* + tp), x^* + tp) - (b, x^* + tp) \quad \text{注意到 } A=A^T, \\&= \frac{1}{2} (Ax^*, x^*) + \frac{t}{2} (Ax^*, p) + \frac{t}{2} (Ap, x^*) + \frac{t^2}{2} (Ap, p) - (b, x^*) - t(b, p) \\&= \boxed{\frac{1}{2} (Ax^*, x^*) - (b, x^*)} + \boxed{\frac{t}{2} [(Ax^*, p) + (Ap, x^*) - 2(b, p)]} + \frac{t^2}{2} (Ap, p) \\&= \varphi(x^*) + t(Ax^* - b, p) + \frac{t^2}{2} (Ap, p) \\&= \varphi(x^*) + \frac{t^2}{2} (Ap, p)\end{aligned}$$

因为 A 为正定矩阵, 所以 $\frac{t^2}{2} (Ap, p) \geq 0$, 故

$$\varphi(x^* + tp) \geq \varphi(x^*)$$

即 x^* 使 $\varphi(x)$ 达到最小。

$$\varphi(\mathbf{x}^* + t\mathbf{p}) = \varphi(\mathbf{x}^*) + t(\mathbf{Ax}^* - \mathbf{b}, \mathbf{p}) + \frac{t^2}{2}(\mathbf{Ap}, \mathbf{p})$$

充分性 设 $\varphi(\mathbf{x}^*) = \min_{\mathbf{x} \in \mathbf{R}^n} \varphi(\mathbf{x})$, 则应有 $\varphi(\mathbf{x}^* + t\mathbf{p})$ 于 $t=0$ 取极小值, 也即 $\forall \mathbf{p} \in \mathbf{R}^n$

$$\left[\varphi'(\mathbf{x}^* + t\mathbf{p}) \right] \Big|_{t=0} = \left[(\mathbf{Ax}^* - \mathbf{b}, \mathbf{p}) + t(\mathbf{Ap}, \mathbf{p}) \right] \Big|_{t=0} = (\mathbf{Ax}^* - \mathbf{b}, \mathbf{p}) = 0$$

从而 $(\mathbf{Ax}^* - \mathbf{b}, \mathbf{p}) = 0 \Leftrightarrow \mathbf{x}^*$ 是 $\mathbf{Ax} = \mathbf{b}$ 的解。

又由 $\varphi(\mathbf{x}^* + t\mathbf{p})$ 于 $t=0$ 取极小值的充分条件, 即得

$(\mathbf{Ap}, \mathbf{p}) = \varphi''(0) > 0 \quad \forall \mathbf{p} \in \mathbf{R}^n$ 故 \mathbf{A} 必为正定矩阵。

定理4.9说明, 求 $\mathbf{Ax} = \mathbf{b}$ 的解的问题等价于求 $\varphi(\mathbf{x})$ 的最小值问题。
在介绍共轭梯度法前, 先介绍较为直观的最速下降法。

4.5.1 最速下降法

取初始向量 \mathbf{x}_0 ，从 \mathbf{x}_0 出发构造向量序列 $\{\mathbf{x}_k\}$ 使 $\varphi(\mathbf{x}_{k-1}) > \varphi(\mathbf{x}_k)$

构造方法：选取方向 \mathbf{y}_0 ，使 $\varphi(x)$ 在 \mathbf{x}_0 处沿 \mathbf{y}_0 方向减小的速度最快。

据多元函数场论可知， \mathbf{y}_0 应为 $\varphi(\mathbf{x})$ 的负梯度方向，即

$$\mathbf{y}_0 = -\nabla \varphi(\mathbf{x}_0) = \mathbf{r}_0 = \mathbf{b} - \mathbf{A}\mathbf{x}_0 \quad \varphi(\mathbf{x}) = \frac{1}{2} \mathbf{x}^T \mathbf{A} \mathbf{x} - \mathbf{x}^T \mathbf{b}$$

再在方向 \mathbf{r}_0 上进行一维极小搜索，即在 $\mathbf{x}_0 + \alpha \mathbf{r}_0$ 中选取 α_0 使得

$\varphi(\mathbf{x}_0 + \alpha \mathbf{r}_0)$ 极小，即求 $\min_{\alpha \in R} \varphi(\mathbf{x}_0 + \alpha \mathbf{r}_0)$

$$\begin{aligned} \frac{d\varphi(\mathbf{x}_0 + \alpha \mathbf{r}_0)}{d\alpha} &= \frac{d}{d\alpha} \left[\varphi(\mathbf{x}_0) + \alpha (\mathbf{A}\mathbf{x}_0 - \mathbf{b}, \mathbf{r}_0) + \frac{\alpha^2}{2} (\mathbf{A}\mathbf{r}_0, \mathbf{r}_0) \right] \\ &= -(\mathbf{r}_0, \mathbf{r}_0) + \alpha (\mathbf{A}\mathbf{r}_0, \mathbf{r}_0) = 0 \end{aligned}$$

则 $\alpha = \alpha_0 = \frac{(r_0, r_0)}{(Ar_0, r_0)}$, 由于 $\frac{d^2}{d\alpha^2} \varphi(x_0 + \alpha r_0) = (Ar_0, r_0) > 0$

故 $\min_{\alpha \in R} \varphi(x_0 + \alpha r_0) = \varphi(x_0 + \alpha r_0)$

令 $x_1 = x_0 + \alpha r_0$, 重复上面的过程, 可得

$$\begin{cases} r_k = b - Ax_k \\ \alpha_k = \frac{(r_k, r_k)}{(Ar_k, r_k)} \\ x_{k+1} = x_k + \alpha_k r_k \end{cases} \quad (4-63)$$

由于 $\varphi(x_0) > \varphi(x_1) > \cdots > \varphi(x_k) > \cdots \geq \varphi(x^*)$, $\{\varphi(x_k)\}$ 存在极限,

而且 $\lim_{k \rightarrow \infty} x_k = x^* = A^{-1}b$

$$(1) \quad (r_{k+1}, r_k) = 0 \quad k = 0, 1, 2, \dots \quad (4-64)$$

还可以证明


$$(2) \quad \|x_k - x^*\|_A \leq \left(\frac{\lambda_1 - \lambda_n}{\lambda_1 + \lambda_n} \right)^k \|x_0 - x^*\|_A \quad (4-65)$$

其中 λ_1, λ_n 分别为 A 的模最大和最小特征值, $\|x\|_A = (Ax, x)^{\frac{1}{2}}$ 。

最速下降的几何意义

取定初始值 $\mathbf{x}^{(0)}$ ，于超椭圆 $\varphi(\mathbf{x}) = \varphi(\mathbf{x}^{(0)})$ 上过 $\mathbf{x}^{(0)}$ ，作其内法线 $\mathbf{r}^{(0)}$ ，它就是 $\varphi(\mathbf{x})$ 在 $\mathbf{x}^{(0)}$ 点的最速下降方向，然后在射线 $\mathbf{x}^{(0)} + \alpha \mathbf{r}^{(0)}$ 上求与 $\varphi(\mathbf{x}) = \varphi(\mathbf{x}^{(0)})$ 的另一交点 $\bar{\mathbf{x}}^{(0)}$ ， $\bar{\mathbf{x}}^{(0)}$ 与 $\mathbf{x}^{(0)}$ 的中点即为 $\mathbf{x}^{(1)}$ ，它也是 $\mathbf{x}^{(0)} + \alpha \mathbf{r}^{(0)}$ 与 $\varphi(\mathbf{x}) = \varphi(\mathbf{x}^{(1)})$ 的切点。

过 $\mathbf{x}^{(1)}$ 再作 $\varphi(\mathbf{x}) = \varphi(\mathbf{x}^{(1)})$ 的内法线 $\mathbf{r}^{(1)}$ ，然后沿着此方向求 $\bar{\mathbf{x}}^{(1)}$ ， $\mathbf{x}^{(2)}$ ，等等 \cdots ，如此继续下去就得到最速下降的迭代序列。



$$\text{验证} \quad (\mathbf{r}_{k+1}, \mathbf{r}_k) = 0 \quad k = 0, 1, 2, \dots \quad (4-64)$$

$$\text{由} \quad \mathbf{x}_{k+1} = \mathbf{x}_k + \alpha_k \mathbf{r}_k$$

$$\text{得} \quad \mathbf{r}_{k+1} = \mathbf{b} - \mathbf{A}\mathbf{x}_{k+1} = \mathbf{b} - \mathbf{A}(\mathbf{x}_k + \alpha_k \mathbf{r}_k) = \mathbf{r}_k - \alpha_k \mathbf{A}\mathbf{r}_k$$

$$\text{从而} \quad (\mathbf{r}_{k+1}, \mathbf{r}_k) = (\mathbf{r}_k, \mathbf{r}_k) - \alpha_k (\mathbf{A}\mathbf{r}_k, \mathbf{r}_k) \quad \alpha_k = \frac{(\mathbf{r}_k, \mathbf{r}_k)}{(\mathbf{A}\mathbf{r}_k, \mathbf{r}_k)}$$

$$= (\mathbf{r}_k, \mathbf{r}_k) - \frac{(\mathbf{r}_k, \mathbf{r}_k)}{(\mathbf{A}\mathbf{r}_k, \mathbf{r}_k)} (\mathbf{A}\mathbf{r}_k, \mathbf{r}_k)$$


$$= (\mathbf{r}_k, \mathbf{r}_k) - (\mathbf{r}_k, \mathbf{r}_k)$$

$$= 0$$

当 λ_1 与 λ_n 相差很大时, 据 (4-65) 可知, $\{x_k\}$ 收敛很慢, 而且当 $\|r_k\|$ 很小时, 由于舍入误差的影响, 由 (4-63) 的计算将出现不稳定现象, 所以在实际计算中很少使用最速下降法。

这是因为当 λ_1 与 λ_n 相差很大时, 椭球面变得非常扁平; 如果 \tilde{x} 位于它的较平坦的一面时, 其内法线 \tilde{r} 就与 \hat{x} 和椭球中心 x^* 的连线方向几乎垂直, 这样 \hat{x} 与 x^* 之间的距离就差不多等于 \tilde{x} 与 x^* 之间的距离, 从而使得最速下降法的收敛速度变得非常慢。

$$\|x_k - x^*\|_A \leq \left(\frac{\lambda_1 - \lambda_n}{\lambda_1 + \lambda_n} \right)^k \|x_0 - x^*\|_A$$



从上述几何解释说明, 负梯度方向并非最合适的方向, 有时它与目标的偏差太大。能否选出比负梯度方向更好而计算量又不是很大的方向为新的下降方向呢? 答案是肯定的。

$$\varphi(\mathbf{x}) = \frac{1}{2} \mathbf{x}^T \mathbf{A} \mathbf{x} - \mathbf{x}^T \mathbf{b} \quad \mathbf{r}_k = \mathbf{b} - \mathbf{A} \mathbf{x}_k \quad \alpha_k = \frac{(\mathbf{r}_k, \mathbf{r}_k)}{(\mathbf{A} \mathbf{r}_k, \mathbf{r}_k)} \quad \mathbf{x}_{k+1} = \mathbf{x}_k + \alpha_k \mathbf{r}_k$$

4.5.2 共轭梯度法（简称CG法）

$$\|\mathbf{x}_k - \mathbf{x}^*\|_A \leq \left(\frac{\lambda_1 - \lambda_n}{\lambda_1 + \lambda_n} \right)^k \|\mathbf{x}_0 - \mathbf{x}^*\|_A$$

从上式可以看出，我们采用一维搜索所沿的方向 $\mathbf{r}_0, \mathbf{r}_1, \dots, \mathbf{r}_k$ 可能使的收敛速度缓慢，因此，我们需要另找一组方向 $\mathbf{p}_0, \mathbf{p}_1, \dots, \mathbf{p}_k$ 进行一维极小搜索。设按方向 $\mathbf{p}_0, \mathbf{p}_1, \dots, \mathbf{p}_k$ 已经进行 k 次一维搜索，已求出 \mathbf{x}_k ，下一步确定进行求解极小问题

$$\min \varphi(\mathbf{x}_k + \alpha \mathbf{p}_k)$$

与最速下降法中的方法一样，令

$$\begin{aligned} \frac{d\varphi(\mathbf{x}_k + \alpha \mathbf{p}_k)}{d\alpha} &= \frac{d}{d\alpha} \left[\varphi(\mathbf{x}_k) + \alpha (\mathbf{A} \mathbf{x}_k - \mathbf{b}, \mathbf{p}_k) + \frac{\alpha^2}{2} (\mathbf{A} \mathbf{p}_k, \mathbf{p}_k) \right] \\ &= (\mathbf{A} \mathbf{x}_k - \mathbf{b}, \mathbf{p}_k) + \alpha (\mathbf{A} \mathbf{p}_k, \mathbf{p}_k) \\ &= -(\mathbf{r}_k, \mathbf{p}_k) + \alpha (\mathbf{A} \mathbf{p}_k, \mathbf{p}_k) = 0 \end{aligned}$$

$$-(\mathbf{r}_k, \mathbf{p}_k) + \alpha (\mathbf{A}\mathbf{p}_k, \mathbf{p}_k) = 0$$

解得

$$\alpha = \alpha_k = \frac{(\mathbf{r}_k, \mathbf{p}_k)}{(\mathbf{A}\mathbf{p}_k, \mathbf{p}_k)} \quad (4-66)$$

从而得到下一个近似解和对应的负梯度向量


$$\mathbf{x}_{k+1} = \mathbf{x}_k + \alpha_k \mathbf{p}_k \quad (4-67)$$

$$\begin{aligned} \mathbf{r}_{k+1} &= \mathbf{b} - \mathbf{A}\mathbf{x}_{k+1} = \mathbf{b} - \mathbf{A}(\mathbf{x}_k + \alpha_k \mathbf{p}_k) \\ &= \mathbf{b} - \mathbf{A}\mathbf{x}_k - \alpha_k \mathbf{A}\mathbf{p}_k = \mathbf{r}_k - \alpha_k \mathbf{A}\mathbf{p}_k \end{aligned} \quad (4-68)$$

下面讨论 $\mathbf{p}_0, \mathbf{p}_1, \dots, \mathbf{p}_k \dots$ 的取法。

开始时取 $\mathbf{p}_0 = \mathbf{r}_0$, 如果 $k \geq 1$ 时, 我们可以证明这样的事实:

上一步 \mathbf{x}_k 的下降方向 \mathbf{p}_k 一定与 \mathbf{r}_{k+1} (当前步 \mathbf{x}_{k+1} 的负梯度方向) 是正交的。



$$\min \varphi(\mathbf{x}_k + \alpha \mathbf{p}_k) \quad \alpha = \alpha_k = \frac{(\mathbf{r}_k, \mathbf{p}_k)}{(A\mathbf{p}_k, \mathbf{p}_k)} \quad (4-66) \quad \mathbf{x}_{k+1} = \mathbf{x}_k + \alpha_k \mathbf{p}_k$$

$$\mathbf{r}_{k+1} = \mathbf{r}_k - \alpha_k A\mathbf{p}_k \quad (4-68) \quad \mathbf{p}_{k+1} = \mathbf{r}_{k+1} + \beta_k \mathbf{p}_k \quad (4-72)$$

$$\begin{aligned} & \min_{\beta} \varphi(\mathbf{x}_{k+1} + \alpha_k (\mathbf{r}_{k+1} + \beta \mathbf{p}_k)) \\ &= \min_{\beta} \varphi((\mathbf{x}_{k+1} + \alpha_k \mathbf{r}_{k+1}) + \alpha_k \beta \mathbf{p}_k) \end{aligned}$$

$$\begin{aligned} \text{令} \quad & \frac{d\varphi((\mathbf{x}_{k+1} + \alpha_k \mathbf{r}_{k+1}) + \alpha_k \beta \mathbf{p}_k)}{d\beta} \\ &= \frac{d}{d\beta} \left[\varphi(\mathbf{x}_{k+1} + \alpha_k \mathbf{r}_{k+1}) + \alpha_k \beta (A(\mathbf{x}_{k+1} + \alpha_k \mathbf{r}_{k+1}) - \mathbf{b}, \mathbf{p}_k) + \frac{(\alpha_k \beta)^2}{2} (A\mathbf{p}_k, \mathbf{p}_k) \right] \\ &= \alpha_k (A\mathbf{x}_{k+1} - \mathbf{b}, \mathbf{p}_k) + \alpha_k^2 (A\mathbf{r}_{k+1}, \mathbf{p}_k) + \alpha_k^2 \beta (A\mathbf{p}_k, \mathbf{p}_k) \\ &= -\alpha_k (\mathbf{r}_{k+1}, \mathbf{p}_k) + \alpha_k^2 (A\mathbf{r}_{k+1}, \mathbf{p}_k) + \alpha_k^2 \beta (A\mathbf{p}_k, \mathbf{p}_k) = 0 \end{aligned}$$

则得

$$\beta_k = -\frac{(\mathbf{r}_{k+1}, A\mathbf{p}_k)}{(A\mathbf{p}_k, \mathbf{p}_k)}$$

$$\min \varphi(\mathbf{x}_k + \alpha \mathbf{p}_k) \quad \alpha = \alpha_k = \frac{(\mathbf{r}_k, \mathbf{p}_k)}{(\mathbf{A}\mathbf{p}_k, \mathbf{p}_k)} \quad (4-66) \quad \mathbf{x}_{k+1} = \mathbf{x}_k + \alpha_k \mathbf{p}_k$$

$$\mathbf{r}_{k+1} = \mathbf{r}_k - \alpha_k \mathbf{A}\mathbf{p}_k \quad (4-68)$$

$$\mathbf{p}_{k+1} = \mathbf{r}_{k+1} + \beta_k \mathbf{p}_k \quad (4-72) \quad \beta_k = -\frac{(\mathbf{r}_{k+1}, \mathbf{A}\mathbf{p}_k)}{(\mathbf{p}_k, \mathbf{A}\mathbf{p}_k)} \quad (4-73)$$

由(4-72)、(4-73)得到的 \mathbf{p}_k ，还可用于简化 α_k 的计算。

因为由(4-68)与(4-66)有

$$\begin{aligned} (\mathbf{r}_{k+1}, \mathbf{p}_k) &= (\mathbf{r}_k - \alpha_k \mathbf{A}\mathbf{p}_k, \mathbf{p}_k) = (\mathbf{r}_k, \mathbf{p}_k) - \alpha_k (\mathbf{A}\mathbf{p}_k, \mathbf{p}_k) \\ &= (\mathbf{r}_k, \mathbf{p}_k) - \frac{(\mathbf{r}_k, \mathbf{p}_k)}{(\mathbf{A}\mathbf{p}_k, \mathbf{p}_k)} (\mathbf{A}\mathbf{p}_k, \mathbf{p}_k) \\ &= (\mathbf{r}_k, \mathbf{p}_k) - (\mathbf{r}_k, \mathbf{p}_k) = 0 \end{aligned}$$

$$\alpha_k = \frac{(\mathbf{r}_k, \mathbf{p}_k)}{(\mathbf{A}\mathbf{p}_k, \mathbf{p}_k)} \quad (\mathbf{r}_{k+1}, \mathbf{p}_k) = 0 \quad \mathbf{p}_k = \mathbf{r}_k + \beta_{k-1}\mathbf{p}_{k-1}$$

$$\begin{aligned} (\mathbf{r}_k, \mathbf{p}_k) &= (\mathbf{r}_k, \mathbf{r}_k + \beta_{k-1}\mathbf{p}_{k-1}) \\ &= (\mathbf{r}_k, \mathbf{r}_k) + \beta_{k-1}(\mathbf{r}_k, \mathbf{p}_{k-1}) = (\mathbf{r}_k, \mathbf{r}_k) \end{aligned} \quad (4-74)$$

故有

$$\alpha_k = \frac{(\mathbf{r}_k, \mathbf{p}_k)}{(\mathbf{A}\mathbf{p}_k, \mathbf{p}_k)} = \frac{(\mathbf{r}_k, \mathbf{r}_k)}{(\mathbf{A}\mathbf{p}_k, \mathbf{p}_k)} \quad (4-75)$$

当 $\mathbf{r}_k \neq \mathbf{0}$ 时, $\alpha_k > 0$ 。

用前面的已有公式, 还可以证明:

$$(1) \quad (\mathbf{r}_i, \mathbf{r}_j) = 0 \quad (i \neq j) \quad (4-76)$$

$$(2) \quad (\mathbf{A}\mathbf{p}_i, \mathbf{p}_j) = (\mathbf{p}_i, \mathbf{A}\mathbf{p}_j) = 0 \quad (i \neq j) \quad (4-77)$$

即 $\mathbf{r}_0, \mathbf{r}_1, \cdots$ 构成正交向量组, $\mathbf{p}_0, \mathbf{p}_1, \cdots$ 构成 \mathbf{A} -正交向量组。

$$\mathbf{r}_{k+1} = \mathbf{r}_k - \alpha_k A \mathbf{p}_k \quad (4-68)$$

$$(\mathbf{r}_i, \mathbf{r}_j) = 0 \quad (i \neq j) \quad (4-76)$$

$$\alpha_k = \frac{(\mathbf{r}_k, \mathbf{r}_k)}{(A \mathbf{p}_k, \mathbf{p}_k)} \quad (4-75)$$

利用 (4-68) 和 (4-76) 还可简化 β_k 的计算

$$\beta_k = -\frac{(\mathbf{r}_{k+1}, A \mathbf{p}_k)}{(\mathbf{p}_k, A \mathbf{p}_k)} = -\frac{(\mathbf{r}_{k+1}, \alpha_k^{-1} (\mathbf{r}_k - \mathbf{r}_{k+1}))}{(\mathbf{p}_k, A \mathbf{p}_k)} \quad \alpha_k A \mathbf{p}_k = \mathbf{r}_k - \mathbf{r}_{k+1}$$

$$= -\frac{\alpha_k^{-1} (\mathbf{r}_{k+1}, \mathbf{r}_k)}{(\mathbf{p}_k, A \mathbf{p}_k)} + \frac{\alpha_k^{-1} (\mathbf{r}_{k+1}, \mathbf{r}_{k+1})}{(\mathbf{p}_k, A \mathbf{p}_k)} \quad \alpha_k^{-1} = \frac{(A \mathbf{p}_k, \mathbf{p}_k)}{(\mathbf{r}_k, \mathbf{r}_k)},$$

$$= \frac{(\cancel{A \mathbf{p}_k}, \cancel{\mathbf{p}_k})}{(\mathbf{r}_k, \mathbf{r}_k)} \cdot \frac{(\mathbf{r}_{k+1}, \mathbf{r}_{k+1})}{(\cancel{A \mathbf{p}_k}, \cancel{\mathbf{p}_k})} = \frac{(\mathbf{r}_{k+1}, \mathbf{r}_{k+1})}{(\mathbf{r}_k, \mathbf{r}_k)} \quad (4-78)$$

当 $\mathbf{r}_{k+1} \neq 0$ 时, $\beta_k > 0$ 。

$$\alpha_k = \frac{(\mathbf{r}_k, \mathbf{r}_k)}{(A \mathbf{p}_k, \mathbf{p}_k)}, \quad \beta_k = \frac{(\mathbf{r}_{k+1}, \mathbf{r}_{k+1})}{(\mathbf{r}_k, \mathbf{r}_k)}$$

共轭梯度法（CG法）：

(1) 任取 $\mathbf{x}_0 \in \mathbf{R}^n$

(2) $\mathbf{r}_0 = \mathbf{b} - \mathbf{A}\mathbf{x}_0$ ，取 $\mathbf{p}_0 = \mathbf{r}_0$

(3) 对 $k=0, 1, 2, \dots$

$$\alpha_k = \frac{(\mathbf{r}_k, \mathbf{r}_k)}{(\mathbf{p}_k, \mathbf{A}\mathbf{p}_k)}$$

$$\mathbf{x}_{k+1} = \mathbf{x}_k + \alpha_k \mathbf{p}_k$$

$$\mathbf{r}_{k+1} = \mathbf{r}_k - \alpha_k \mathbf{A}\mathbf{p}_k$$

$$\beta_k = \frac{(\mathbf{r}_{k+1}, \mathbf{r}_{k+1})}{(\mathbf{r}_k, \mathbf{r}_k)}$$

$$\mathbf{p}_{k+1} = \mathbf{r}_{k+1} + \beta_k \mathbf{p}_k$$

若有 $\mathbf{r}_k = \mathbf{0}$ ，则 $\mathbf{r}_k = \mathbf{b} - \mathbf{A}\mathbf{x}_k$ 。

若有 $(\mathbf{A}\mathbf{p}_k, \mathbf{p}_k) = 0$ 时，由于 \mathbf{A} 为正定阵，必有 $\mathbf{p}_k = \mathbf{0}$ ，则由 (4-74) 有

$$(\mathbf{r}_k, \mathbf{r}_k) = (\mathbf{p}_k, \mathbf{r}_k) = 0$$

即 $\mathbf{r}_k = \mathbf{b} - \mathbf{A}\mathbf{x}_k = \mathbf{0}$ 。

在计算过程中若有 $\mathbf{r}_k = \mathbf{0}$ 或 $(\mathbf{A}\mathbf{p}_k, \mathbf{p}_k) = 0$ 时计算终止，即有 $\mathbf{x}_k = \mathbf{x}^*$ 。



DUT

大连理工大学

DALIAN UNIVERSITY OF TECHNOLOGY

由于 n 维空间中正交向量组的向量个数最多只有 n 个，所以 r_0, r_1, \dots, r_n 中至少有一个为零向量，若 $r_j=0$ ，则 $r_j=x^*$ 。所以使用CG法求解 n 阶线性方程组，理论上最多 n 步便可得到精确解，因此，也可称为直接法。但是，由于舍入误差的影响， $\{r_k\}$ 的正交性很难达到，所以在实际计算时往往不能在 n 步得到精确解，因此，通常将CG法还是作为逐次逼近法使用。

例1 用CG法解线性方程组
$$\begin{pmatrix} 2 & 0 & 1 \\ 0 & 2 & 1 \\ 1 & 1 & 2 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix} \quad \mathbf{x}^* = \begin{pmatrix} 0.5 \\ 0.5 \\ 0 \end{pmatrix}.$$

解 显然方程组的系数阵为对称正定阵，取 $\mathbf{x}_0 = (0, 0, 0)^T$

$$\mathbf{r}_0 = \mathbf{b} - A\mathbf{x}_0 = \mathbf{b} = \mathbf{p}_0 = (1, 1, 1)^T,$$

对 $k=0, 1, 2, \dots$ 计算: $\alpha_k, \mathbf{x}_{k+1}, \mathbf{r}_{k+1}, \beta_k, \mathbf{p}_{k+1}$. $\alpha_0 = \frac{(\mathbf{r}_0, \mathbf{r}_0)}{(\mathbf{p}_0, A\mathbf{p}_0)} = \frac{3}{10},$

$$\mathbf{x}_1 = \mathbf{x}_0 + \alpha_0 \mathbf{p}_0 = \left(\frac{3}{10}, \frac{3}{10}, \frac{3}{10} \right)^T, \quad \mathbf{r}_1 = \mathbf{r}_0 - \alpha_0 A\mathbf{p}_0 = \left(\frac{1}{10}, \frac{1}{10}, \frac{1}{10} \right)^T - \left(\frac{2}{10}, \frac{9}{10}, \frac{12}{10} \right)^T$$

$$\beta_0 = \frac{(\mathbf{r}_1, \mathbf{r}_1)}{(\mathbf{r}_0, \mathbf{r}_0)} = \frac{6}{100} \times \frac{1}{3} = \frac{1}{50} \quad \mathbf{p}_1 = \mathbf{r}_1 + \beta_0 \mathbf{p}_0 = \left(\frac{31}{50}, \frac{1}{10}, \frac{2}{10} \right)^T + \left(\frac{1}{50}, \frac{1}{50}, \frac{1}{50} \right)^T$$

$$\alpha_1 = \frac{(\mathbf{r}_1, \mathbf{r}_1)}{(\mathbf{p}_1, A\mathbf{p}_1)} = \frac{6}{100} \times \frac{2500}{90} = \frac{5}{3}$$

$$\mathbf{x}_2 = \mathbf{x}_1 + \alpha_1 \mathbf{p}_1 = \frac{3}{10}(1, 1, 1)^T + \frac{1}{10}(2, 2, -3)^T = \frac{1}{2}(1, 1, 0)^T$$

$$\mathbf{r}_2 = \mathbf{r}_1 - \alpha_1 A\mathbf{p}_1 = \frac{1}{10}(1, 1, -2)^T - \frac{5}{3} \times \frac{3}{50}(1, 1, -2)^T = (0, 0, 0)^T$$

则方程组的解为 $\mathbf{x}_2 = (0.5, 0.5, 0)^T$ 。



DUT

大连理工大学

DALIAN UNIVERSITY OF TECHNOLOGY

对于病态的线性方程组，CG法的收敛速度是很慢的，为了改进收敛速度，可以对方程组进行预处理，使系数矩阵的条件数降低，这种方法称**预处理共轭梯度法**（PCG法），PCG方法是目前求解病态线性方程组的有效方法之一，因此，它已成为很多计算工作者关心的方法之一，对此有兴趣的读者可以参阅文献[6]。



DUT

大连理工大学

DALIAN UNIVERSITY OF TECHNOLOGY

THE END